환경 텍스트 데이터 분석 입문

2026. 03. 18.

한국환경연구원 AI 데이터팀
연구위원 진대용

텍스트 마이닝

- 텍스트 마이닝(Text Mining)
  - 텍스트 마이닝은 글(텍스트)를 캐낸다는 의미, 여기서 마이닝은 'mining' 을 나타낸 것으로 '(광산을)채굴하다 ' 의 뜻
  - 단어의 출현 빈도, 단어 간 관계성 등을 파악하여 유의미한 정보를 추출하는 것
  - 빈도수의 마법

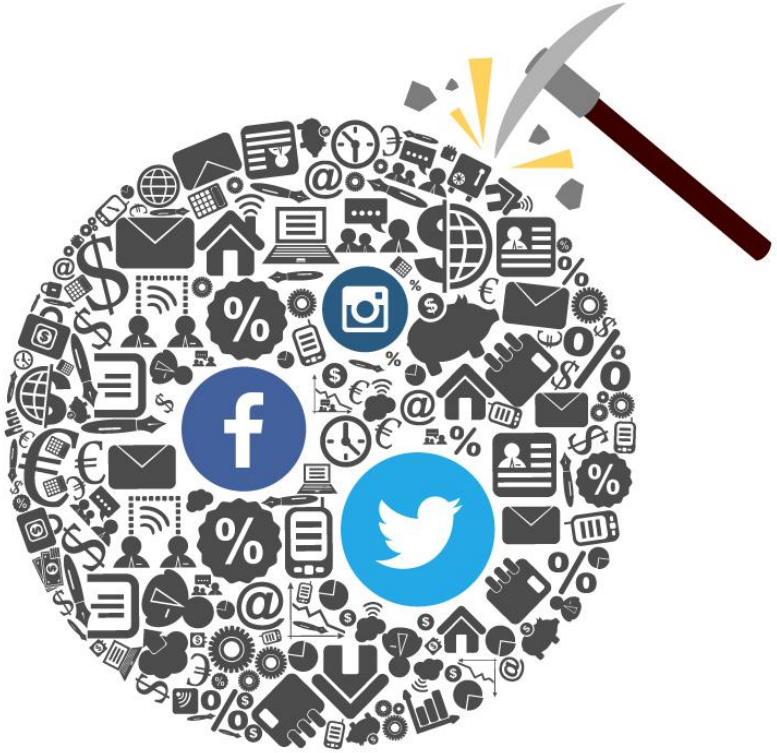

텍스트 마이닝 관련 키워드

NLP
Lexical/Syntax analysis
Named entity recognition
POS tagging
Keyword Frequency

Crawling/ Scrapping
Reqeust
Beatifulsoup

Latent semantic analysis
Co-occurrence
Dimension reduction
(SVD,PCA)

LLM
GPT, Gemini, Claude
Llama, Qwen, Deepseek
Prompt Engineering
LangChain, LangGraph
Vector DB
RAG, MCP

Language modeling
Uni/Bigram/N-gram

Embedding
Word2Vec
Sentence Transformer
BGE
OpenAI Embeddings

Sentiment analysis
Lexicon based
Machine learning based

Visualization
Word Cloud
Keyword Network

Topic modeling
LDA
LSA/pLSA

Document representation
Bag-of-words
TF, TF-IDF
Embedding

Document/Sentence Classification
SVM, Naïve Bayes, RNN, Transformer

Latent semantic analysis
Co-occurrence
Dimension reduction
(SVD,PCA)

Preprocessing
Tokenization
Cleaning
Stemming/
Lemmatization
Stopword Filtering

실습환경 구축

- Python 3.12에서 실습
- 패키지 설치
  - python.exe -m pip install --upgrade pip
  - pip install jupyter
  - pip install requests beautifulsoup4
  - pip install kiwipiepy
  - pip install gensim
  - pip install sentence-transformers
  - pip install matplotlib
  - pip install scikit-learn
  - pip install seaborn

텍스트 마이닝의 분석 과정

01 문서집단 선택 및 수집

분석에 활용할 텍스트 자료를 선정 및 수집 수행

02 형태소 분석 및 품사 태깅

문장을 형태소 단위로 분리하고 품사 태깅 수행

03 불용어 처리

텍스트 분석에 필요 없는 단어 제거

04 단어-문서 행렬 구성

단어 빈도수 산출 및 중요도(TF-IDF 등) 설정

05 텍스트 마이닝 분석

키워드 빈도, 토픽 모델링, 감성분석 등 적용

06 결과 분석

분석 결과 해석 및 시사점 도출

	환경	쓰레기	악취	소음
Doc1	4	2	2	0
Doc2	1	4	3	0
Doc3	1	0	0	2
...				
DocN	2	1	1	2

문서집단 선택 및 텍스트 수집

- **크롤링/스크래핑**
  - 프로그램(코드)이 웹사이트를 돌아다니며 필요한 글자 정보를 **직접 긁어오는 방식**
- **API 수집**
  - 네이버 등 플랫폼이 **공식적으로 제공하는 통로(함수, 코드 등)**를 통해 데이터를 정식으로 받는 방식
- **전문 도구(빅카인즈 등)**
  - 뉴스나 공공데이터처럼 이미 잘 정리된 데이터를 사이트에서 직접 내려받는 방식

문서집단 선택 및 텍스트 수집

- 크롤링 예시
  - 자료 : https://n.news.naver.com/mnews/article/469/0000916179?sid=101

한국일보 ✓구독중

'탄소중립' 목표 기후금융에 10년간 790조 투입한다

박세인 기자

입력 2026.02.25. 오전 10:20 · 수정 2026.02.25. 오후 5:18 기사원문

추천 1 가가

금융위원장 주재 '생산적 금융 대전환 회의'
2035 NDC 목표, 7년 420조→10년 790조
투자기업 배출량 따지는 '금융 배출량'도 집적
ESG 공시, 자산 30조 원 이상 상장사 의무화

문서집단 선택 및 텍스트 수집

- 네이버 API 활용 예시

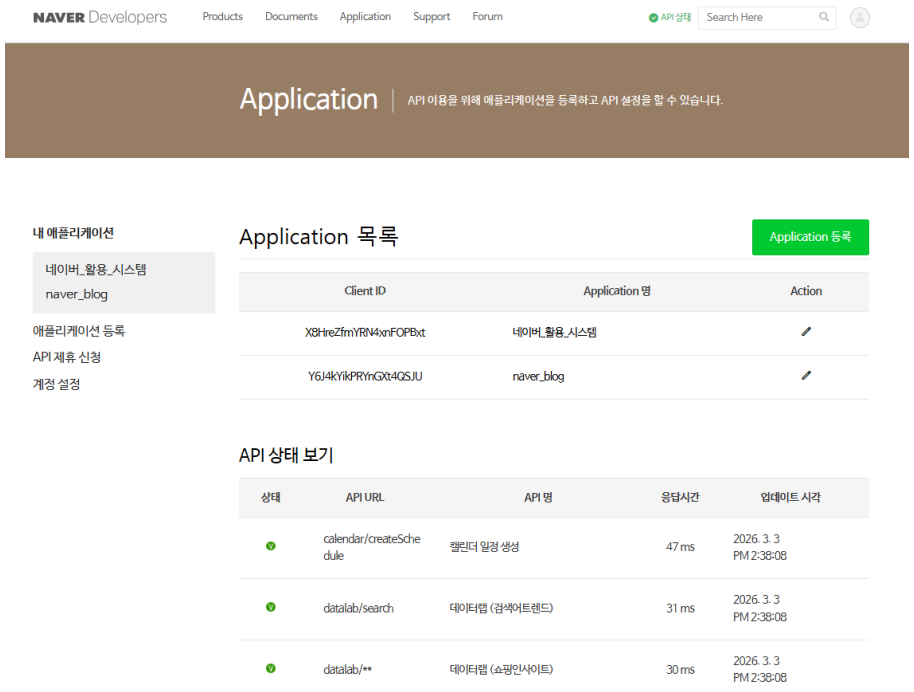

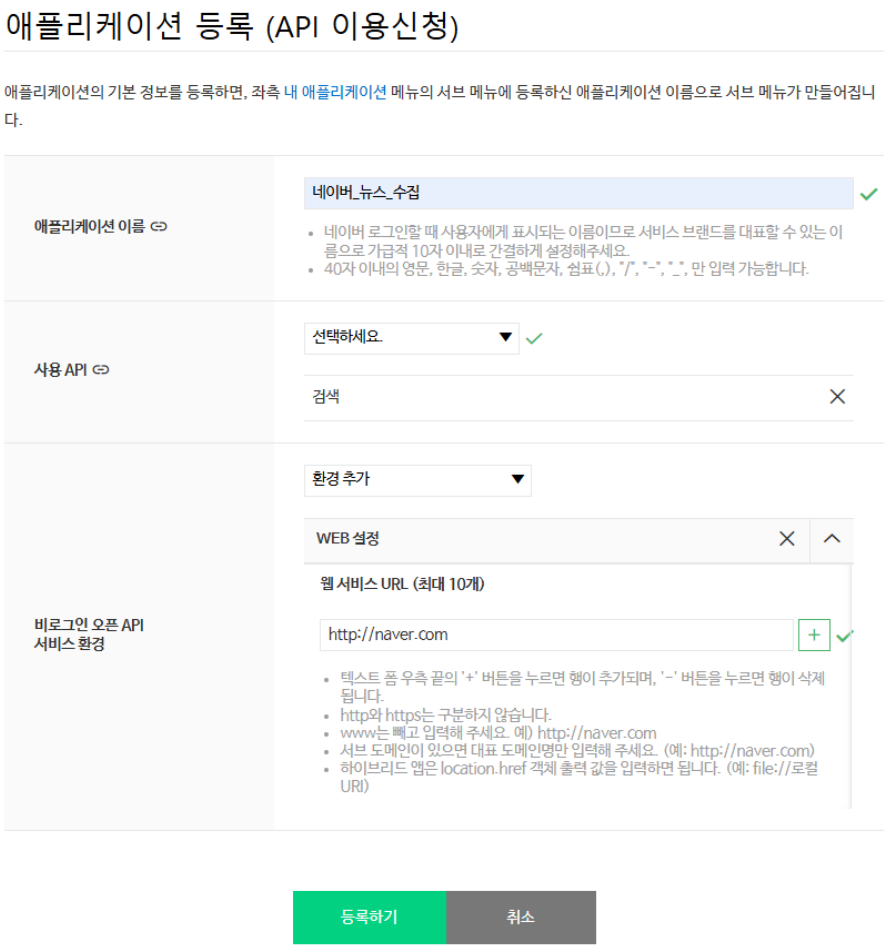

문서집단 선택 및 텍스트 수집

- 네이버 API 활용 예시

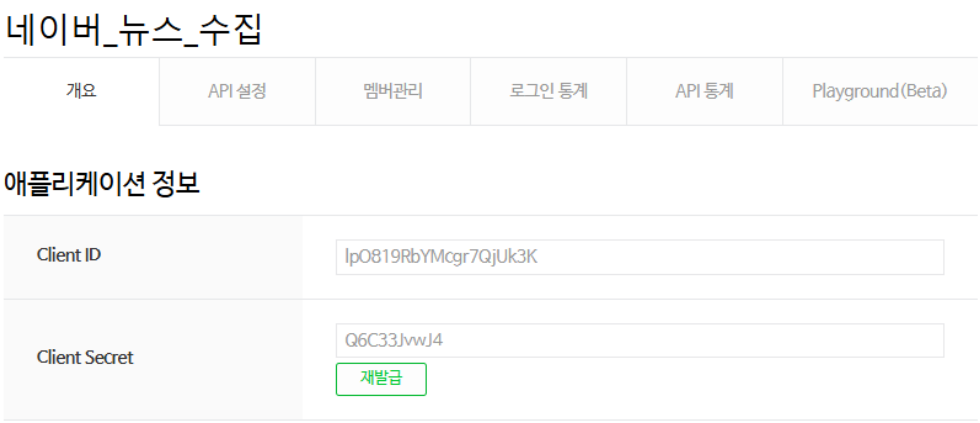

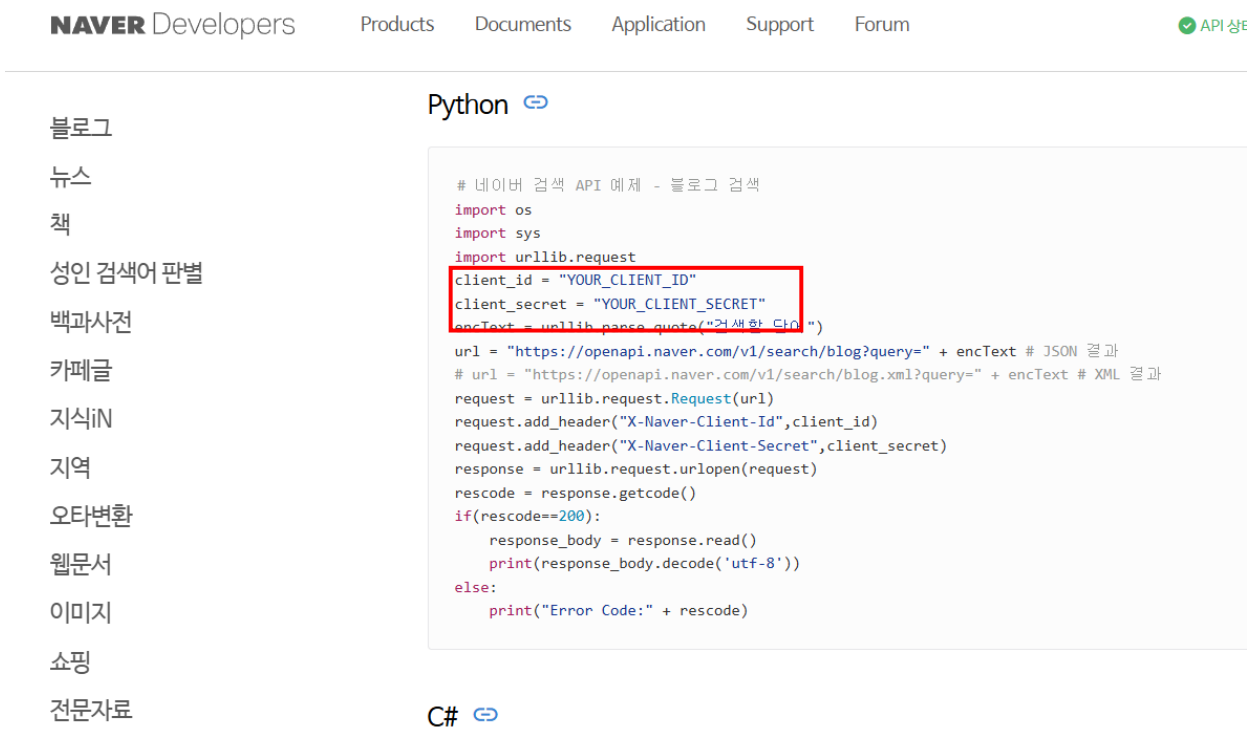

문서집단 선택 및 텍스트 수집

- 전문 도구(웹사이트 활용)

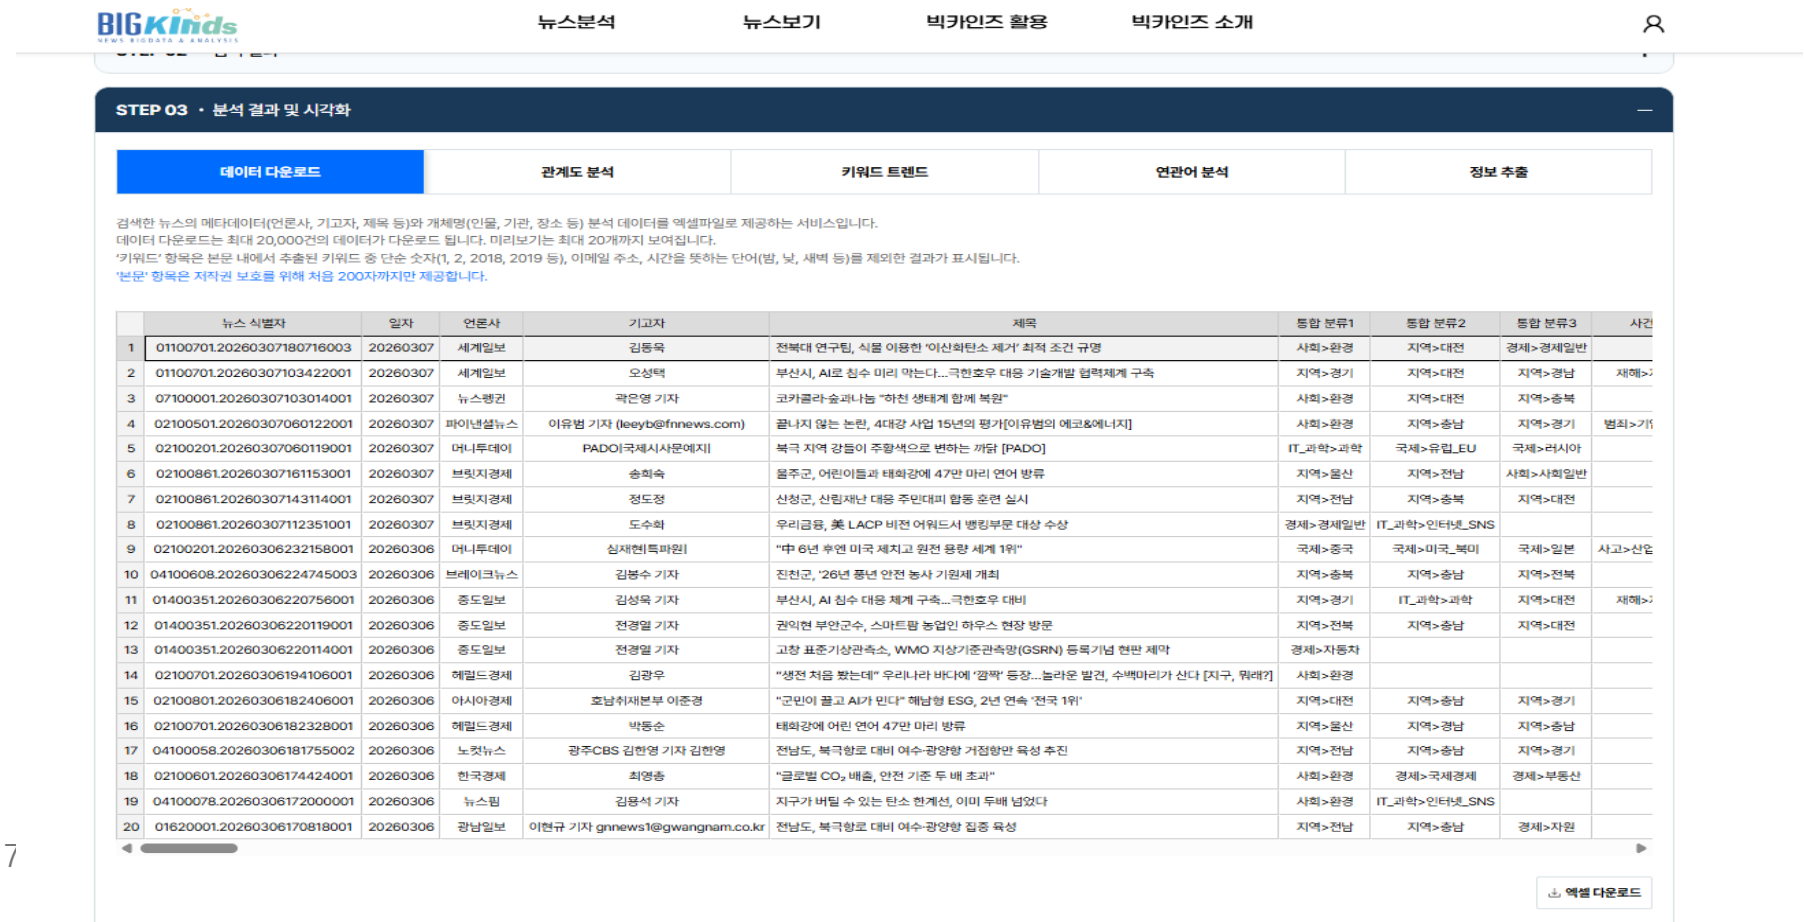

	뉴스 식별자	일자	언론사	기고자	제목	통합 분류1	통합 분류2	통합 분류3	사건
1	01100701.20260307180716003	20260307	세계일보	김동욱	전북대 연구팀, 식물 이용한 '이산화탄소 제거' 최적 조건 규명	사회>환경	지역>대전	경제>경제일반	
2	01100701.20260307103422001	20260307	세계일보	오성택	부산시, AI로 침수 미리 막는다…극한호우 대응 기술개발 협력체계 구축	지역>경기	지역>대전	지역>경남	재해>기
3	07100001.20260307103014001	20260307	뉴스뱅킨	곽은영 기자	코카콜라·숲과나눔 "하천 생태계 함께 복원"	사회>환경	지역>대전	지역>충북	
4	02100501.20260307060122001	20260307	파이낸셜뉴스	이유범 기자 (leeyb@fnnews.com)	끝나지 않는 논란, 4대강 사업 15년의 평가[이유범의 에코&에너지]	사회>환경	지역>충남	지역>경기	범죄>기
5	02100201.20260307060119001	20260307	머니투데이	PADO국제시사문예지	북극 지역 강들이 주황색으로 변하는 까닭 [PADO]	IT_과학>과학	국제>유럽_EU	국제>러시아	
6	02100861.20260307161153001	20260307	브릿지경제	송희숙	울주군, 어린이들과 태화강에 47만 마리 연어 방류	지역>울산	지역>전남	사회>사회일반	
7	02100861.20260307143114001	20260307	브릿지경제	정도정	산청군, 산림재난 대응 주민대피 합동 훈련 실시	지역>전남	지역>충북	지역>대전	
8	02100861.20260307112351001	20260307	브릿지경제	도수화	우리금융, 美 LACP 비전 어워드서 뱅킹부문 대상 수상	경제>경제일반	IT_과학>인터넷_SNS		
9	02100201.20260306232158001	20260306	머니투데이	심재현특파원	"中 6년 후엔 미국 제치고 원전 용량 세계 1위"	국제>중국	국제>미국_북미	국제>일본	사고>산업
10	04100608.20260306224745003	20260306	브레이크뉴스	김봉수 기자	진천군, '26년 풍년 안전 농사 기원제 개최	지역>충북	지역>충남	지역>전북	
11	01400351.20260306220756001	20260306	중도일보	김성욱 기자	부산시, AI 침수 대응 체계 구축…극한호우 대비	지역>경기	IT_과학>과학	지역>대전	재해>기
12	01400351.20260306220119001	20260306	중도일보	전경열 기자	권익현 부안군수, 스마트팜 농업인 하우스 현장 방문	지역>전북	지역>충남	지역>대전	
13	01400351.20260306220114001	20260306	중도일보	전경열 기자	고창 표준기상관측소, WMO 지상기준관측망(GSRN) 등록기념 현판 제막	경제>자동차			
14	02100701.20260306194106001	20260306	헤럴드경제	김광우	"생전 처음 봤는데" 우리나라 바다에 '깜짝' 등장…놀라운 발견, 수백마리가 산다 [지구, 뭐래?]	사회>환경			
15	02100801.20260306182406001	20260306	아시아경제	호남취재본부 이준경	"군민이 끌고 AI가 민다" 해남형 ESG, 2년 연속 '전국 1위'	지역>대전	지역>충남	지역>경기	
16	02100701.20260306182328001	20260306	헤럴드경제	박동순	태화강에 어린 연어 47만 마리 방류	지역>울산	지역>경남	지역>충남	
17	04100058.20260306181755002	20260306	노컷뉴스	광주CBS 김한영 기자 김한영	전남도, 북극항로 대비 여수·광양항 거점항만 육성 추진	지역>전남	지역>충남	지역>경기	
18	02100601.20260306174424001	20260306	한국경제	최영송	"글로벌 CO_2 배출, 안전 기준 두 배 초과"	사회>환경	경제>국제경제	경제>부동산	
19	04100078.20260306172000001	20260306	뉴스핌	김용석 기자	지구가 버틸 수 있는 탄소 한계선, 이미 두배 넘었다	사회>환경	IT_과학>인터넷_SNS		
20	01620001.20260306170818001	20260306	광남일보	이현규 기자 gnnews1@gwangnam.co.kr	전남도, 북극항로 대비 여수·광양항 집중 육성	지역>전남	지역>충남	경제>자원	

텍스트 분석과정 실습

- 실습파일
  - 01_텍스트_수집.ipynb

형태소 분석 및 품사 태깅

- 토큰(Token)
  - 분석하기 위해 쪼갠 최소 단위의 조각
  - **형태소**, 한글자 등
- 형태소
  - 의미(뜻)를 가진 가장 작은 말의 단위
- 형태소 분석(Morphological Analysis)
  - **문장을 형태소로 분해**하는 작업

- 형태소 분석 예시

  - 아버지가 방에 들어가신다.

  ['아버지', '가', '방', '에', '들어가신다']

형태소 분석 및 품사 태깅

- 사전(Dictionary)
  - 형태소 분석기가 텍스트를 형태소 단위로 인식하고 해석하기 위한 기준
  - 기본 사전(Built-in Dictionary)
    - 일반 명사, 동사, 형용사, 조사, 어미 등 기본 품사 데이터 포함 (범용 목적의 기초 어휘 사전)
  - 사용자 정의사전
    - 특정 도메인이나 분석 목적에 맞춰 사용자가 직접 정의한 커스텀 사전
    - 신조어, 고유명사, 전문 용어 등 기본사전 미등록 어휘 보완

형태소 분석 및 품사 태깅

- 주요 형태소 분석기

분석기	선호도 / 사용성	핵심 장점	단점
Kiwi (키위)	현재 실무 선호도 높음	매우 빠른 속도, **사용자 사전 추가 쉬움**, Windows 완전 지원, 유지보수 활발	MeCab 대비 자료가 적음
MeCab (매캡) 은전한닢 분석기	전통적 표준	최고 수준의 분석 속도, 오랜 기간 검증, 대규모 코퍼스 처리 안정적	설치 번거로움, 사용자 사전 추가 복잡, Python 연동 설정 까다로움, 2018년 이후 업데이트X
Okt (Open Korean Text)	SNS 텍스트에서 많이 사용	설치 매우 쉬움, 이모지·SNS 텍스트 처리 강점	분석 정확도 낮은 편, 속도 느림, 대규모 처리에 부적합, 사용자 사전 추가 어려움

형태소 분석 및 품사 태깅

- 품사태깅(POS tagging)
  - 쪼개진 형태소마다 '명사', '동사', '조사' 같은 이름표(태그)를 붙여주는 작업
- 한국어 형태소 분석기는 대부분 품사태깅도 같이 함

- 품사태깅

  ['아버지', '가', '방', '에', '들어가신다']

형태소	품사 태깅
아버지	명사 (NNG)
가	주격 조사 (JKS)
방	명사 (NNG)
에	부사격 조사 (JKB)
들어가신다	동사 (VV)

불용어 처리

- 불용어(Stopwords) 처리
  - 텍스트 분석에서 의미가 없는 단어(특히 조사, 접미사, 불필요한 키워드 등)를 제거

- 예시 : ‘아버지’

  - 아버지가 방에 들어가신다.

  ['~~아버지',~~ '가', '방', '에', '들어가신다']

단어-문서 행렬의 구성

- **단어-문서 행렬(Term-Document Matrix)**
  - 행(Row)은 문서, 열(Column)은 단어로 구성된 표
  - 각 문서에 단어가 나타난 빈도수(횟수)를 숫자로 기록
  - 텍스트를 숫자로 바꿔 컴퓨터가 연산할 수 있게 만듬
    - 열합을 하면 키워드 빈도수
    - 문서의 정보를 요약
    - 키워드간 거리 계산 가능

문서	분석 결과
Doc1	[환경, 환경, 환경, 환경, 쓰레기, 쓰레기, 악취, 악취, 보호, 실천, 해결]
Doc2	[환경, 미세먼지, 미세먼지, 쓰레기, 쓰레기, 쓰레기, 쓰레기, 악취, 악취, 악취, 오염, 문제]
Doc3	[환경, 소음, 소음, 조성, 배려]
DocN	[환경, 환경, 미세먼지, 미세먼지, 미세먼지, 미세먼지, 쓰레기, 악취, 소음, 소음, 위협, 발생]

	환경	미세먼지	쓰레기	악취	소음
Doc1	4	0	2	2	0
Doc2	1	2	4	3	0
Doc3	1	0	0	0	2
…					
DocN	2	4	1	1	2

단어-문서 행렬의 구성

- TF vs TF-IDF
  - **TF (Term Frequency) : 단순 빈도수**
  - IDF (Inverse Document Frequency)
    - 특정 단어가 전체 문서에서 등장하는 빈도의 역수
    - IDF는 단어의 희소성 측정 (여러 문서에 흔하게 나타날수록 낮은 점수)
  - TF-IDF (Term Frequency Inverse Document Frequency)
    - 빈도수를 기반으로 하되 문서에 자주 등장하는 단어에 패널티

$$w_{x,y} = tf_{x,y} \times \log\left(\frac{N}{df_x}\right)$$

TF-IDF

Term x within document y

$tf_{x,y}$ = frequency of x in y

df_x = number of documents containing x

N = total number of documents

1. TF : '환경 ' 문서에 5번 등장, TF = 5
2. IDF : log (전체 문서 100개 / 단어가 포함된 문서 10개) = 1
3. TF-IDF = TF × IDF = 5

- 유니그램(unigram) vs 바이그램(bigram)
  - 온실가스 감축 : unigram (온실가스, 감축), bigram (온실가스 감축)
  - 기후변화 협약 : unigram (기후변화, 협약), bigram (기후변화 협약)

텍스트 분석과정 실습

- 실습에 활용할 문서
  - Gemini AI로 생성한 40개의 기사
- 실습파일
  - 2_텍스트_분석_기본.ipynb

Word2vec : 워드 **임베딩**

- 워드 임베딩 (대표 방법론 : Word2vec)
  - **단어를 벡터(좌표)로 변환 (유사 문맥 단어 → 유사 공간)**
  - **예시:** " 수질오염 " → [0.32, -0.2, 0.48, ...]
  - **키워드 사전에 없을 경우 답을 못함 (모르는 단어 나오면 바보가 됨)**
  - **단어 거리(유사도) 계산**, 유사어 처리, 연관 키워드 분석 등
  - CBOW / Skip-gram
    - CBOW(Continuous Bag of Words) : 주변 단어를 이용하여 특정 단어를 예측
    - Skip-gram : 특정 단어를 이용하여 주변 단어를 예측

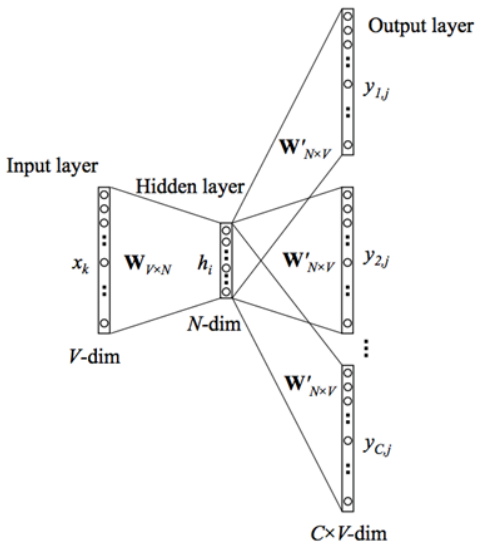

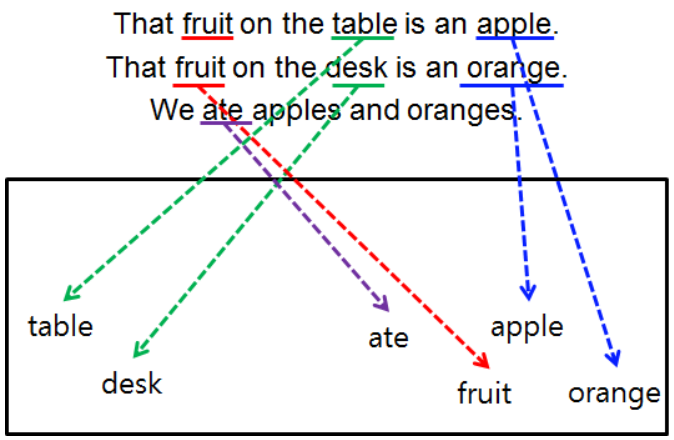

"유사한 문맥에 있는 단어는 유사한 좌표로 변환"

Mikolov, Tomas, et al. "Efficient estimation of word representations in vector space." arXiv preprint arXiv:1301.3781 (2013).

Word2vec : 워드 **임베딩**

- 실습파일
  - 3_Word2Vec.ipynb

Sentence Transformer : 문장 **임베딩**

- 문장 임베딩 (Sentence Embedding)
  - **문장을 벡터(좌표)로 변환**
  - **예시: "환경오염 개선이 필요하다." → [0.12, -0.5, 0.88, ...]**
  - 두 문장이 얼마나 가까운지 계산할 수 있음
  - 사전학습 모델 이용이 용이
- 문장 유사도 비교
  - 단어가 똑같지 않아도 **뜻이 비슷하면** 서로 가깝게 배치 (유사한 의미의 문장은 유사한 좌표로 변환)
    - **문장 A :** "오늘 날씨 정말 좋다."
    - **문장 B :** "현재 기상이 매우 쾌적하네요."
    - **결과:** 두 문장은 단어가 하나도 겹치지 않지만, SentenceTransformer는 두 문장의 거리가 매우 가깝다고 판단.

Reimers, Nils, and Iryna Gurevych. "Sentence-bert: Sentence embeddings using siamese bert-networks." *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)*. 2019.

Sentence Transformer : 문장 **임베딩**

- 활용 예시
  - "물고기 떼죽음"을 검색해도 단어가 다른 '어류 폐사 보고서' 를 맥락으로 탐색
  - “숨쉬기 답답함”, " 뿌연 시야” 등 각기 다른 텍스트를 “미세먼지” 이슈로 통합
  - "냉장고", "소파" 등 제각각인 투기 신고를 '대형 폐기물' 카테고리로 자동 분류

구분	Word2Vec (옛날 방식)	SentenceTransformer (요즘 방식)
사용방식	내 데이터로 처음부터 학습해야 성능이 나옴 (특히 한글은 괜찮은 Pre-trained 모델 부재)	이미 수조 개의 문장을읽은 **프리트레이닝(Pre-trained) 모델을 그냥 가져다 씀**
단위	단어(Word) 단위	문장(Sentence) 전체 맥락
지능 수준	단순 동시출현 기반 (단어 나열)	문맥 파악 가능 (진짜 의미 이해)

Sentence Transformer : 문장 **임베딩**

- 실습파일
  - 4_Sentence_Transformer.ipynb
- Sentence-BERT model (약 500MB)

  서울대 전산언어학 연구실(Computational Linguistics Lab) 개발하고 공개한 **한국어 문장 임베딩 전용 사전 학습 모델**

Park, Suzi, and Hyopil Shin. "Kr-sbert: A pre-trained korean-specific sentence-bert model." 2021,

상용임베딩 모델

Embedding models

OpenAI offers two powerful third-generation embedding model (denoted by `-3` in the model ID). Read the embedding v3 announcement blog post for more details.

Usage is priced per input token. Below is an example of pricing pages of text per US dollar (assuming ~800 tokens per page):

Model	~ Pages per dollar	Performance on MTEB eval	Max input
text-embedding-3-small	62,500	62.3%	8192
text-embedding-3-large	9,615	64.6%	8192
text-embedding-ada-002	12,500	61.0%	8192

By default, the length of the embedding vector is `1536` for `text-embedding-3-small` or `3072` for `text-embedding-3-large`. To reduce the embedding's dimensions without losing its concept-representing properties, pass in the dimensions parameter. Find more detail on embedding dimensions in the embedding use case section.

자료 : https://developers.openai.com/api/docs/guides/embeddings/

모든 정보가 임베딩으로..

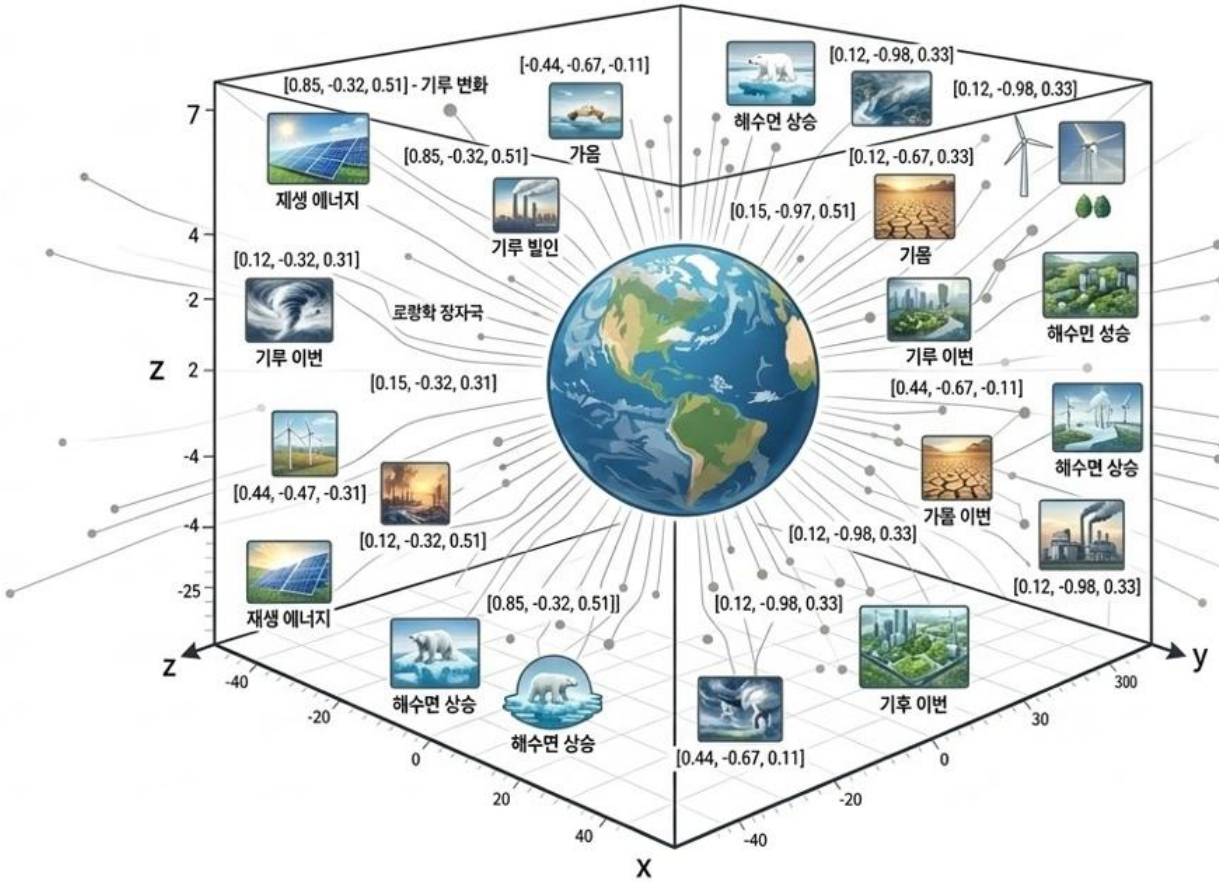

정보를 적절한 좌표(벡터)공간에

매핑하는 것은 아주 어려운 일임,

하지만 기 구축된 모델을 잘 활용

할 경우 쉽게 할 수 있음

비슷한 정보를 찾아 가까운 곳에

가져다 놓기만 하면...

키워드 네트워크 분석

- 키워드 네트워크 분석
  - 텍스트 내 키워드 간의 동시 출현(Co-occurrence) 또는 연관성 관계를 그래프로 시각화그래프 구성
  - 그래프 모형 활용
    - **노드(Node) 와 엣지(Edge)를 정의**
    - 노드와 엣지는 연구자의 판단에 따라 여러 방법으로 정의 할수 있음
- 예시 네트워크
  - 노드 (node) : 키워드
    - 노드 크기 : 빈도수
  - 엣지 (edge) : 키워드 사이의 연관성 강도를 선으로 표현
    - 동시 출현 빈도수

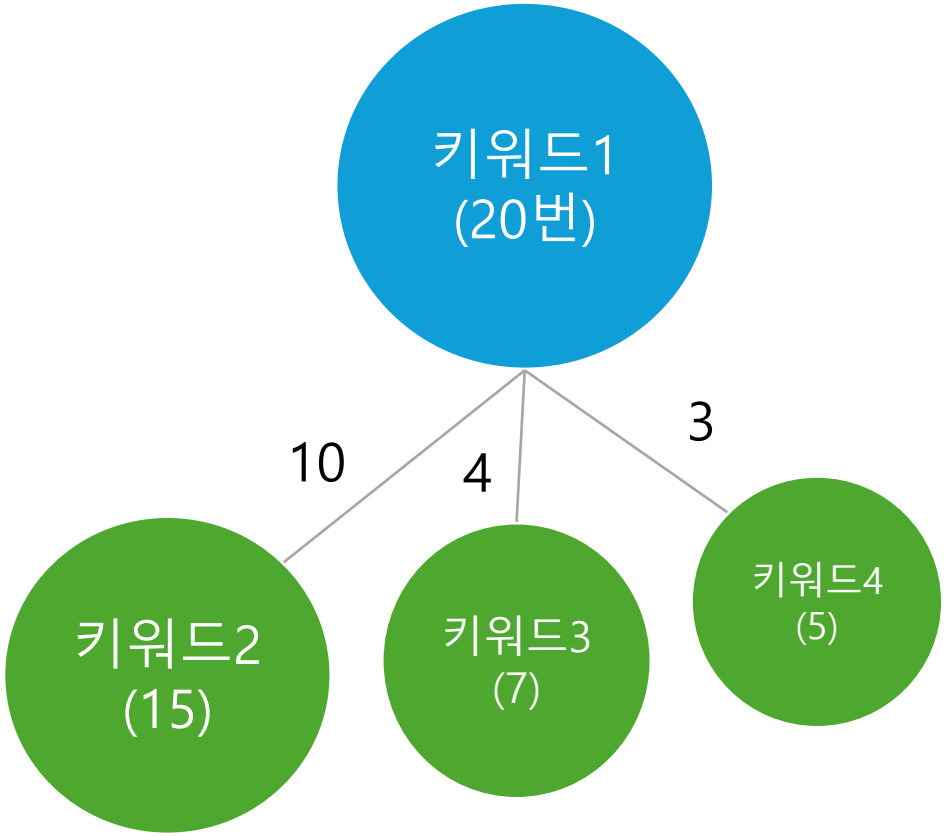

키워드 네트워크 분석

- 실습파일
  - 5_키워드_네트워크_분석.ipynb

경청해 주셔서 감사합니다.